ĐỀ TÀI NCKH

3 SV · họp 20:30 tối thứ Năm · giao 22/11/2026

Áp dụng học máy trong phân tích thông tin chung và thông tin bổ sung giữa hồ sơ kiểu hình tế bào và biểu hiện gen khi tế bào bị quá biểu hiện gen hoặc bị xử lý bằng hợp chất hóa học

Sau khi tế bào bị **quá biểu hiện một gen** hoặc **xử lý bằng hợp chất hóa học**, nhóm đo **hồ sơ kiểu hình** (ảnh nhuộm huỳnh quang) và **mức biểu hiện gen** (mRNA). Một phần thay đổi thấy được ở cả hai phép đo (có thể dự đoán chéo); một phần chỉ thấy rõ ở ảnh hoặc chỉ ở mRNA (ví dụ thuốc đổi hình tế bào mà ít đổi phiên mã, hoặc ngược lại — Haghighi; Way). Ba sinh viên cùng quy trình; sau NCKH mỗi người một đồ án.

NCKH · 3 SV · họp 20:30 tối thứ Năm

Giao bài 22/11/2026

HAI PHÉP ĐO TRONG DỰ ÁN

Hai phép đo → hai hồ sơ số

L1000 · biểu hiện gen

Tế bào → đo mRNA ~978 landmark → **vector GE**

Subramanian · Haghighi · trạng thái phiên mã
không phải toàn bộ RNA-seq

Cell Painting · kiểu hình

Nhuộm → Ảnh → CellProfiler đặc trưng → **vector CP**

Bray 2016 · nhân / ER / ty thể / actin…
hình dạng · cường độ · kết cấu

Điểm	L1000	Cell Painting
Đầu vào	lysate / mẫu phiên mã	tế bào cố định, nhuộm huỳnh quang
Đầu ra	~978 số mức mRNA landmark	hàng trăm–nghìn đặc trưng hình thái
Layout Rosetta	Hai bộ đĩa song song · cùng sơ đồ nhiễu loạn · không cùng một giếng	

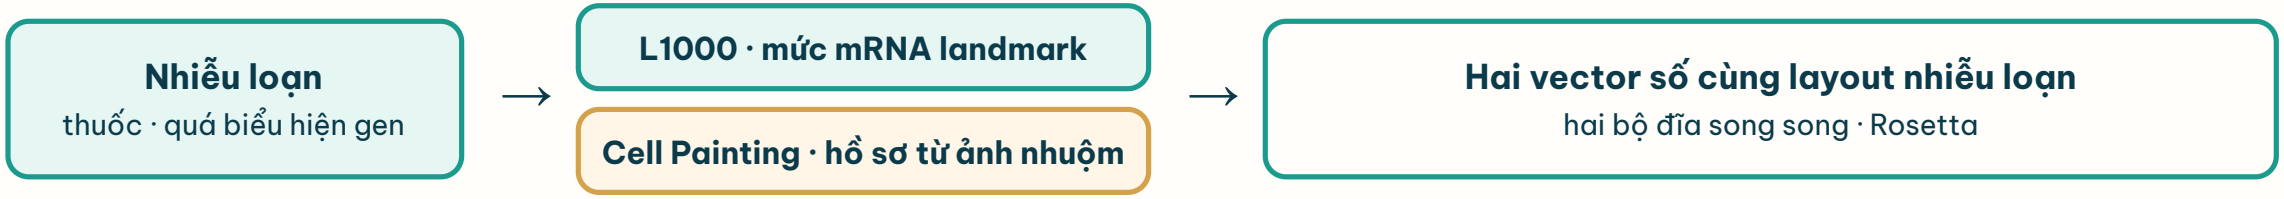
Hai hồ sơ và dữ liệu — đọc trước khi xem sơ đồ

Ký hiệu	Đọc là	Nghĩa ngắn
CP	Cell Painting	Hồ sơ số rút từ ảnh tế bào đã nhuộm huỳnh quang (hình dạng, cường độ, kết cấu).
GE	Gene expression	Mức biểu hiện gen; trong dự án này = vector mức **mRNA** từ L1000.
L1000	Library of 1000	Phép đo ~978 gen **landmark** (bản phiên mã mRNA), không phải toàn bộ transcriptome.
landmark	gen điểm mốc	Bộ gen L1000 đo trực tiếp; giữ tên Anh như trong paper.
Rosetta	cpg0003-rosetta	Bộ dữ liệu có *cả* CP và L1000 cùng layout nhiễu loạn (neo nhóm).
TA-ORF	tập quá biểu hiện	Tập con Rosetta: tế bào bị quá biểu hiện một gen (ORF).
MoA	mechanism of action	Cơ chế tác dụng của hợp chất / thuốc.
batch / plate / well	lô / đĩa / giếng	Nguồn nhiễu kỹ thuật (máy, ngày chạy, vị trí giếng) — SV A chỉnh.

Toán và học máy dùng trong nhóm

Ký hiệu	Đọc là	Nghĩa ngắn
PCA / SVD	thành phần chính / phân rã	Phân tích hướng biến thiên chính của ma trận đặc trưng; bước nền cho whitening.
whitening / sphering	làm trắng / "tròn hóa"	Biến đổi hồ sơ theo hiệp phương sai giếng đối chứng để giảm nhiễu kỹ thuật.
TVN	Typical Variation Normalization	Quy trình Ando: PCA + chuẩn hóa trục + CORAL theo lô (dạng sphering đầy đủ hơn).
CORAL	correlation alignment	Căn chỉnh ma trận tương quan giữa các lô thí nghiệm.
Harmony / ComBat	chỉnh batch	Hai phương pháp chỉnh nhiễu lô khác — SV A so sánh với sphering/TVN.
Lasso	hồi quy ℓ_1	Hồi quy tuyến tính có phạt thưa — baseline dự đoán chéo (SV B).
MLP	multi-layer perceptron	Mạng nơ-ron nhiều lớp — baseline phi tuyến của paper (SV B).
early / late fusion	ghép sớm / muộn	Ghép sớm = nối vector CP+GE; ghép muộn = trung bình xác suất hai bộ phân loại.
RGCCA	Regularized GCCA	Phân tích tương quan chính tắc tổng quát hóa có chỉnh hóa — rồi ghép trong không gian chung (SV C).
R^2 · % gen · Jaccard · F1 · mAP	độ đo	R^2 / % gen = dự đoán chéo; Jaccard / F1 = cơ chế thuốc; mAP / % replicating = chất lượng hồ sơ sau chỉnh nhiễu.

Bài toán: hai hồ sơ số sau nhiễu loạn — ba hướng tính



SV	Câu hỏi tính toán	Phương pháp	Độ đo
A	Làm sạch nhiễu kỹ thuật trên hồ sơ ảnh	SVD, PCA, sphering, TVN, CORAL; Harmony, ComBat	percent replicating, mAP
B	Hai hồ sơ dự đoán chéo được bao nhiêu?	Lasso, MLP	R^2, % gen dự đoán được
C	Ghép hai hồ sơ có đoán cơ chế thuốc tốt hơn?	Early / late fusion, RGCCA, phân loại	Jaccard, F1

Ba mục đích đo được

1 · Thông tin chung

CP ↔ GE

dự đoán chéo · Lasso/MLP

SV B

2 · Thông tin bổ sung

CP + GE

ghép · early/late/RGCCA

SV C

3 · Giảm nhiễu kỹ thuật

CP thô → CP đã chỉnh

sphering · TVN · …

SV A · rồi B/C đo lại

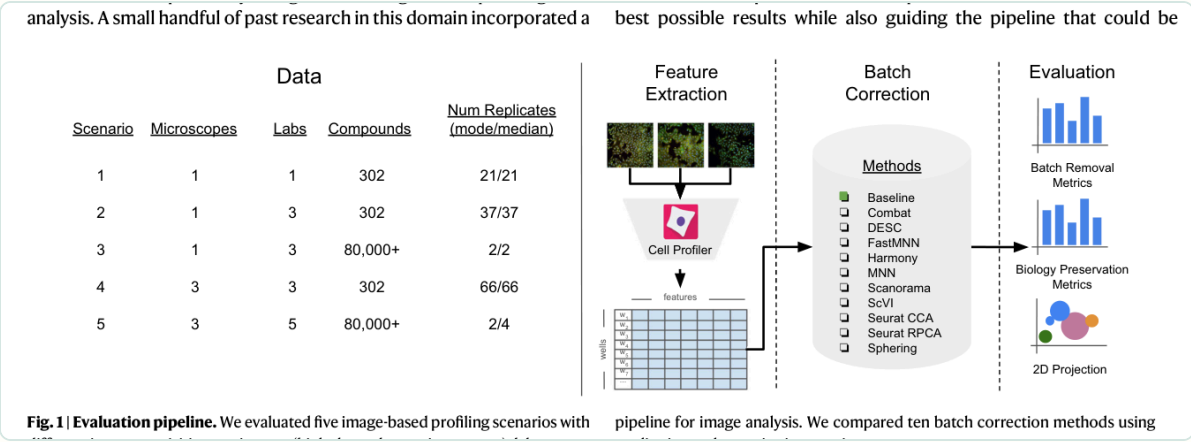
Mục đích	Ý nghĩa	Việc làm trên máy	Tiêu chí thành công
Thông tin chung	Phần thay đổi tế bào mà *cả ảnh lẫn mRNA đều thể hiện*, nên đoán được qua lại giữa hai hồ sơ.	Học hàm: ảnh → mRNA và mRNA → ảnh (Lasso, MLP).	R^2 đủ tốt so với xáo trộn ngẫu nhiên · báo **% gen dự đoán được**.
Thông tin bổ sung	Phần chỉ rõ ở *một* phép đo (ví dụ thuốc đổi hình nhưng ít đổi phiên mã), nên cần *ghép* hai hồ sơ.	Nối / kết hợp CP+GE rồi phân loại cơ chế thuốc.	Jaccard / F1 khi ghép **cao hơn** (hoặc không kém) so với chỉ dùng một hồ sơ.
Giảm nhiễu kỹ thuật	Đĩa/lô/vị trí giếng làm lệch số liệu giả; làm sạch trên hồ sơ ảnh trước khi so sánh.	Sphering, TVN, … trên CP; B và C chạy lại trên bản đã chỉnh.	% replicating / mAP tốt hơn · % gen hoặc MoA **đo lại** sau chỉnh nhiễu.

Ứng dụng: ba việc lab làm được từ hai hồ sơ



Ứng dụng	Đầu vào lab	Đầu ra hữu ích	Ai làm
① Cơ chế thuốc	hồ sơ chất mới + thư viện đã biết	nhóm cơ chế gợi ý	C
② Chức năng gen	quá biểu hiện gen + control	cụm gen cùng kiểu hồ sơ	Rosetta / Rohban
③ Ưu tiên phép đo	ảnh đã chạy · (tuỳ) L1000	% gen suy được từ ảnh	B (+ A)

A — chỉnh nhiễu kỹ thuật trên hồ sơ Cell Painting (Arevalo 2024, Fig. 1)



Nguồn: Arevalo et al., Nat Commun 2024, Fig. 1 · DOI 10.1038/s41467-024-50613-5

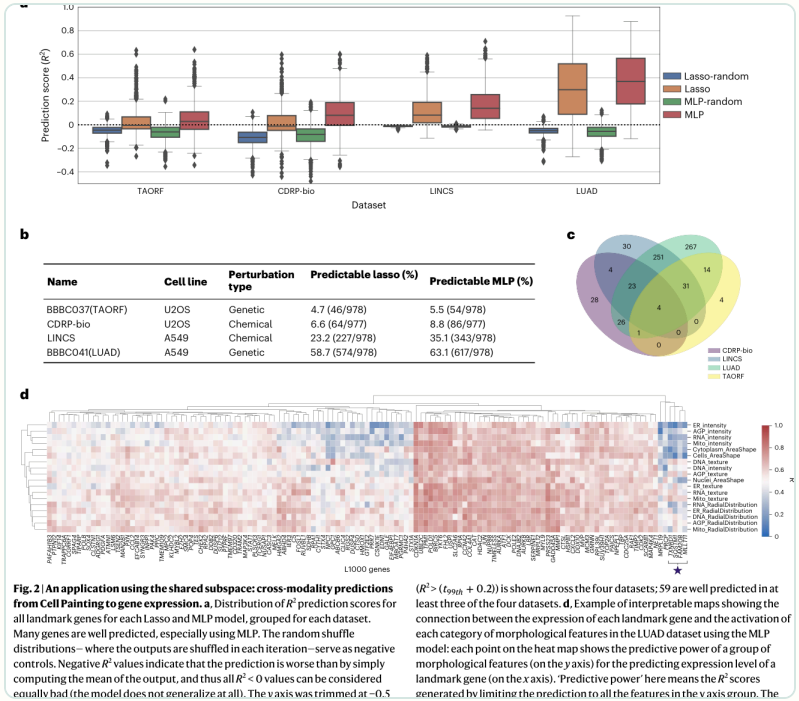
Giảm khác biệt kỹ thuật (máy, lab, lô) trên hồ sơ đặc trưng; đo **loại bỏ batch** và **bảo toàn tín hiệu sinh học**.

Phương pháp: SVD, PCA, whitening / sphering, TVN, CORAL; so sánh Harmony, ComBat.

Độ đo: percent replicating, mAP.

> **Nhiễu kỹ thuật = đĩa / lô / vị trí giếng — không phải tín hiệu kiểu hình cần giữ (Ando).**

B — dự đoán chéo kiểu hình ↔ biểu hiện gen (Haghighi 2022, Fig. 2)



Name	Cell line	Perturbation type	Predictable lasso (%)	Predictable MLP (%)
BBBC037(TAORF)	U2OS	Genetic	4.7 (46/978)	5.5 (54/978)
CDRP-bio	U2OS	Chemical	6.6 (64/977)	8.8 (86/977)
LINCS	A549	Chemical	23.2 (227/978)	35.1 (343/978)
BBBC041(LUAD)	A549	Genetic	58.7 (574/978)	63.1 (617/978)

Fig. 2 | An application using the shared subspace: cross-modality predictions from Cell Painting to gene expression. a, Distribution of R^2 prediction scores for all landmark genes for each Lasso and MLP model, grouped for each dataset. Many genes are well predicted, especially using MLP. The random shuffle distributions—where the outputs are shuffled in each iteration—serve as negative controls. Negative R^2 values indicate that the prediction is worse than by simply computing the mean of the output, and thus all $R^2 < 0$ values can be considered equally bad (the model does not generalize at all). The y axis was trimmed at −0.5 ($R^2 > (t_{99th} + 0.2)$) is shown across the four datasets; 59 are well predicted in at least three of the four datasets. **d**, Example of interpretable maps showing the connection between the expression of each landmark gene and the activation of each category of morphological features in the LUAD dataset using the MLP model: each point on the heat map shows the predictive power of a group of morphological features (on the *y* axis) for the predicting expression level of a landmark gene (on the *x* axis). 'Predictive power' here means the R^2 scores generated by limiting the prediction to all the features in the y axis group. The

Nguồn: Haghighi et al., Nat Methods 2022, Fig. 2 · DOI 10.1038/s41592-022-01667-0 · TA-ORF ~4,7% / 5,5%

Đo **thông tin chung**: học hàm dự đoán mức mRNA landmark từ hồ sơ Cell Painting (và chiều ngược).

Phương pháp: Lasso, MLP.

Độ đo: R^2, % gen dự đoán được (so với xáo trộn ngẫu nhiên).

> **Trên TA-ORF, paper báo ~4,7% / 5,5% gen dự đoán được — nhóm báo cùng hướng số liệu.**

C — ghép hai hồ sơ để đoán cơ chế thuốc (Haghighi 2022, Fig. 4)

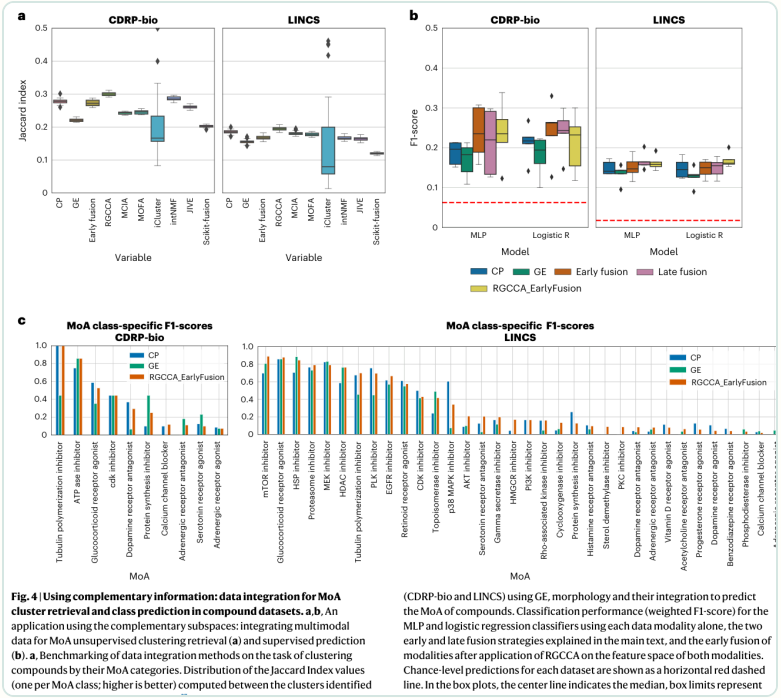


Fig. 4 | Using complementary information: data integration for MoA cluster retrieval and class prediction in compound datasets. a,**b**, An application using the complementary subspaces: integrating multimodal data for MoA unsupervised clustering retrieval (**a**) and supervised prediction (**b**). **a**, Benchmarking of data integration methods on the task of clustering compounds by their MoA categories. Distribution of the Jaccard Index values (one per MoA class; higher is better) computed between the clusters identified (CDRP-bio and LINCS) using GE, morphology and their integration to predict the MoA of compounds. Classification performance (weighted F1-score) for the MLP and logistic regression classifiers using each data modality alone, the two early and late fusion strategies explained in the main text, and the early fusion of modalities after application of RGCCA on the feature space of both modalities. Chance-level predictions for each dataset are shown as a horizontal red dashed line. In the box plots, the center line indicates the median, box limits represent

Nguồn: Haghighi et al., Nat Methods 2022, Fig. 4 · DOI 10.1038/s41592-022-01667-0 · CDRP-bio & LINCS

Đo **thông tin bổ sung**: ghép hai hồ sơ có giúp đoán cơ chế thuốc tốt hơn từng phép đo đơn không.

Phương pháp: early fusion, late fusion, RGCCA, phân loại.

Độ đo: Jaccard, F1.

> **Fig. 4 chạy trên CDRP-bio và LINCS — hợp chất có nhãn cơ chế.**

DỮ LIỆU · TẦNG 1 — NEO MULTIMODAL (BẮT BUỘC)

Chỉ Rosetta có cả L1000 và hồ sơ từ Cell Painting cùng layout

cpg0003-rosetta → LUAD | LINCS | CDRP | TA-ORF

Mỗi tập có thư mục `CellPainting/` và `L1000/`. Bộ tầng 2–3 (slide sau) hỗ trợ chỉnh nhiễu / đối chiếu ảnh.

Mục	Link / lệnh
Portal	https://broad.io/rosetta/
DOI paper	10.1038/s41592-022-01667-0
Code	github.com/carpenter-singh-lab/2022_Haghighi_NatureMethods
Gallery ID	`cpg0003-rosetta` (~8,5 GB số) · mục lục: complete_datasets

```
aws s3 sync --no-sign-request ^
  s3://cellpainting-gallery/cpg0003-rosetta/broad/workspace/curated_preprocessed_data ^
  ./data/raw/rosetta_curated
```

Trong curated: **LUAD**, **LINCS-Pilot1**, **CDRP**, **TA-ORF** — mỗi tập có thư mục CellPainting/ và L1000/.

Hướng dẫn S3: broadinstitute.github.io/cellpainting-gallery/download_instructions.html

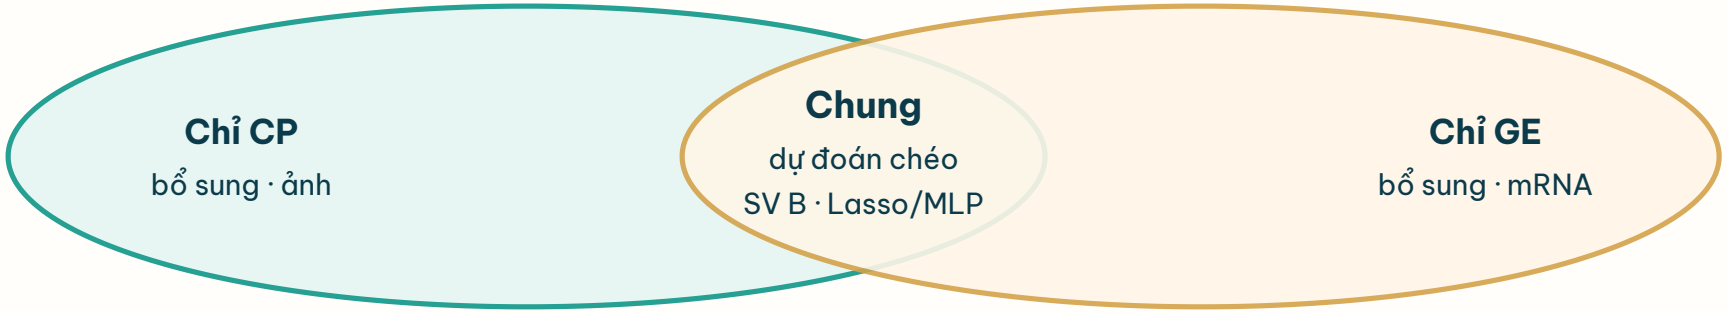
JUMP · Arevalo · CPJUMP1 · Way · GEO — đúng vai trò

Bộ	Vai trò trong dự án	Link tải
Arevalo + Zenodo	SV A: benchmark chỉnh batch	GitHub · Zenodo 10.5281/zenodo.11644046
cpg0016-jump	SV A: hồ sơ JUMP (ORF/CRISPR/thuốc ở tầng ảnh) — dùng profile đã xử lý, không tải raw 358 TB	`aws s3 ls --no-sign-request s3://cellpainting-gallery/cpg0016-jump/` · gallery
cpg0000-jump-pilot (CPJUMP1)	Mở rộng: ORF/CRISPR/thuốc — chỉ Cell Painting	`s3://cellpainting-gallery/cpg0000-jump-pilot/` · DOI 10.1038/s41592-024-02241-6
cpg0004-lincs (Way)	Đối chiếu complementary (thuốc); Rosetta đã có LINCS-Pilot1	`s3://cellpainting-gallery/cpg0004-lincs/` · DOI 10.1016/j.cels.2022.10.001
GEO L1000	Mở rộng RNA ngoài Rosetta (không lõi 4 tháng)	GSE70138 · GSE92742 · clue.io

Chi tiết đủ lệnh: `data/DATA.md`. Bucket chung: cellpainting-gallery.s3.amazonaws.com

Thông tin giữa hai hồ sơ

Gồm **phần chung** (dự đoán chéo) và **phần bổ sung** (chỉ một phép đo thấy rõ).



Hai vùng ngoài (chỉ CP hoặc chỉ GE): SV C ghép hai hồ sơ cho cơ chế thuốc (Fig. 4).

Phần	Ý nghĩa	Ví dụ	Ai đo
Chung	cả ảnh và mRNA phản ánh	y ≈ f(X_CP)	B · % gen
Bổ sung	chỉ một phép đo thấy rõ	thuốc đổi hình, ít đổi phiên mã	C · Jaccard/F1

Song song trước — đồng bộ sau khi A giao hồ sơ



SV	Tháng 1–2 (song song)	Sau khi A giao CP_1
A	Pipeline chỉnh nhiễu · bảng độ đo · chuẩn bị `shared/` v0	Benchmark JUMP/Arevalo · so sánh Harmony/ComBat · viết ĐA A · có thể v1
B	Lasso/MLP · % gen trên CP chưa chỉnh (4 tập)	Chạy lại một lần trên CP đã chỉnh
C	Early/late/RGCCA · MoA trên hợp chất (CP chưa chỉnh)	Thêm cột Δ trước/sau trên CP_1

Họp 20:30 tối thứ Năm · mốc đồng bộ: A có `shared/` profile v0 cuối tháng 2 (không phải hết việc của A)

ĐỒ ÁN SV A

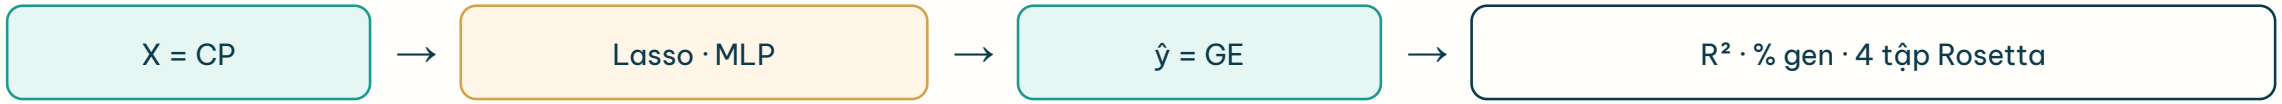
Đồ án A — chuẩn hóa & chỉnh nhiễu hồ sơ kiểu hình



Phần	Mục chính	~Tr
1 Cơ bản	Nhiễu loạn & profiling; Cell Painting; batch/plate/well; PCA & whitening; JUMP/Rosetta CP	15–20
2 Phương pháp	Sphering; TVN 3 bước; Harmony/ComBat; percent replicating / mAP	20–30
3 Thực nghiệm	Bảng ≥3 phương pháp × độ đo; ablation; case	~20
KL	Kết luận	3–5

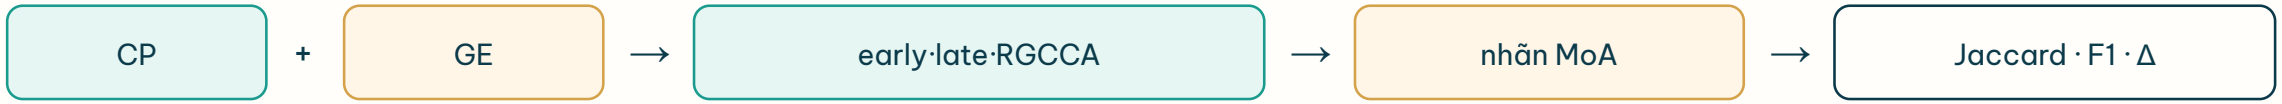
ĐỒ ÁN SV B

Đồ án B — học máy dự đoán biểu hiện gen từ kiểu hình



Phần	Mục chính	~Tr
1 Cơ bản	L1000 landmark; hồ sơ CP; thông tin chung / bổ sung; TA-ORF yếu đã biết	15–20
2 Phương pháp	Khớp ID; Lasso; MLP; xáo trộn null; hai chiều CP ↔ GE	20–30
3 Thực nghiệm	TA-ORF vs LUAD/LINCS; ảnh hưởng tiền xử lý từ A	~20
KL	Kết luận	3–5

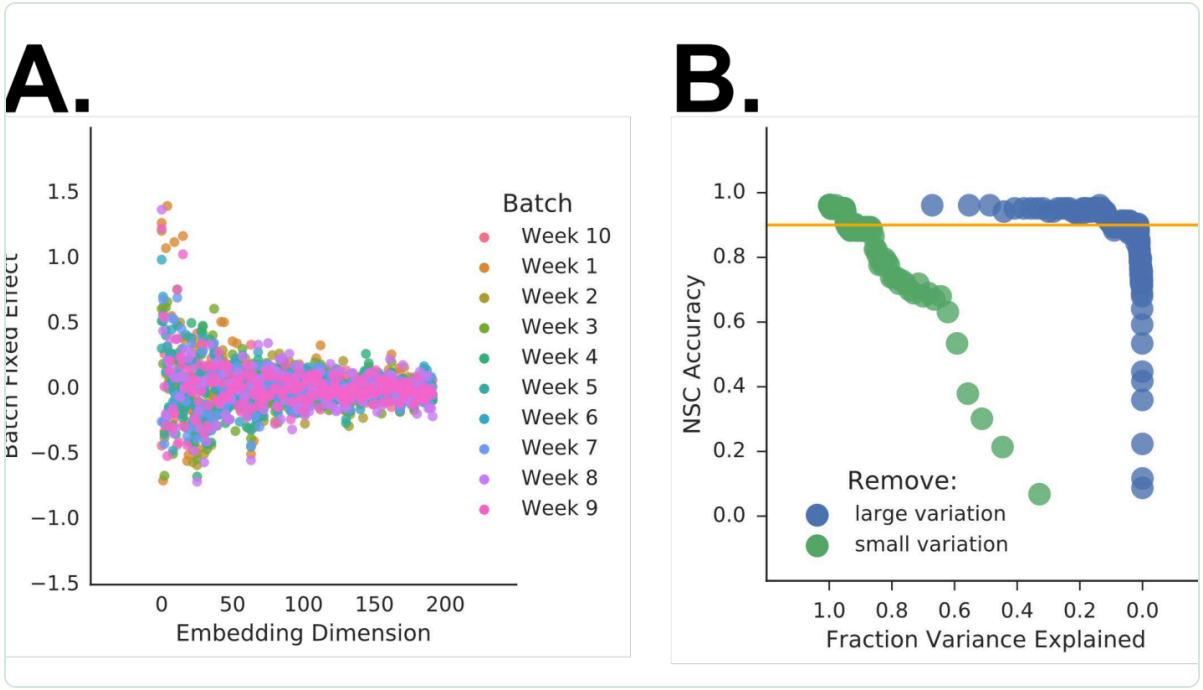
Đồ án C — học máy ghép hồ sơ để đoán cơ chế thuốc



Phần	Mục chính	~Tr
1 Cơ bản	Thông tin bổ sung & ghép; cơ chế thuốc từ hồ sơ; vai A/B	15–20
2 Phương pháp	Jaccard; ghép sớm/muộn/RGCCA; quy trình A→B; mô phỏng *mở rộng*	20–30
3 Thực nghiệm	Ghép vs một hồ sơ; bảng trước/sau chỉnh nhiễu	~20
KL	Kết luận	3–5

CHI TIẾT A · TVN (ANDO)

TVN tách nhiễu kỹ thuật khỏi biến thiên kiểu hình (Ando Fig. 3)



Nguồn (crop khung hình): Ando et al., bioRxiv 2017, Fig. 3 · DOI 10.1101/161422 · PDF trang 19.

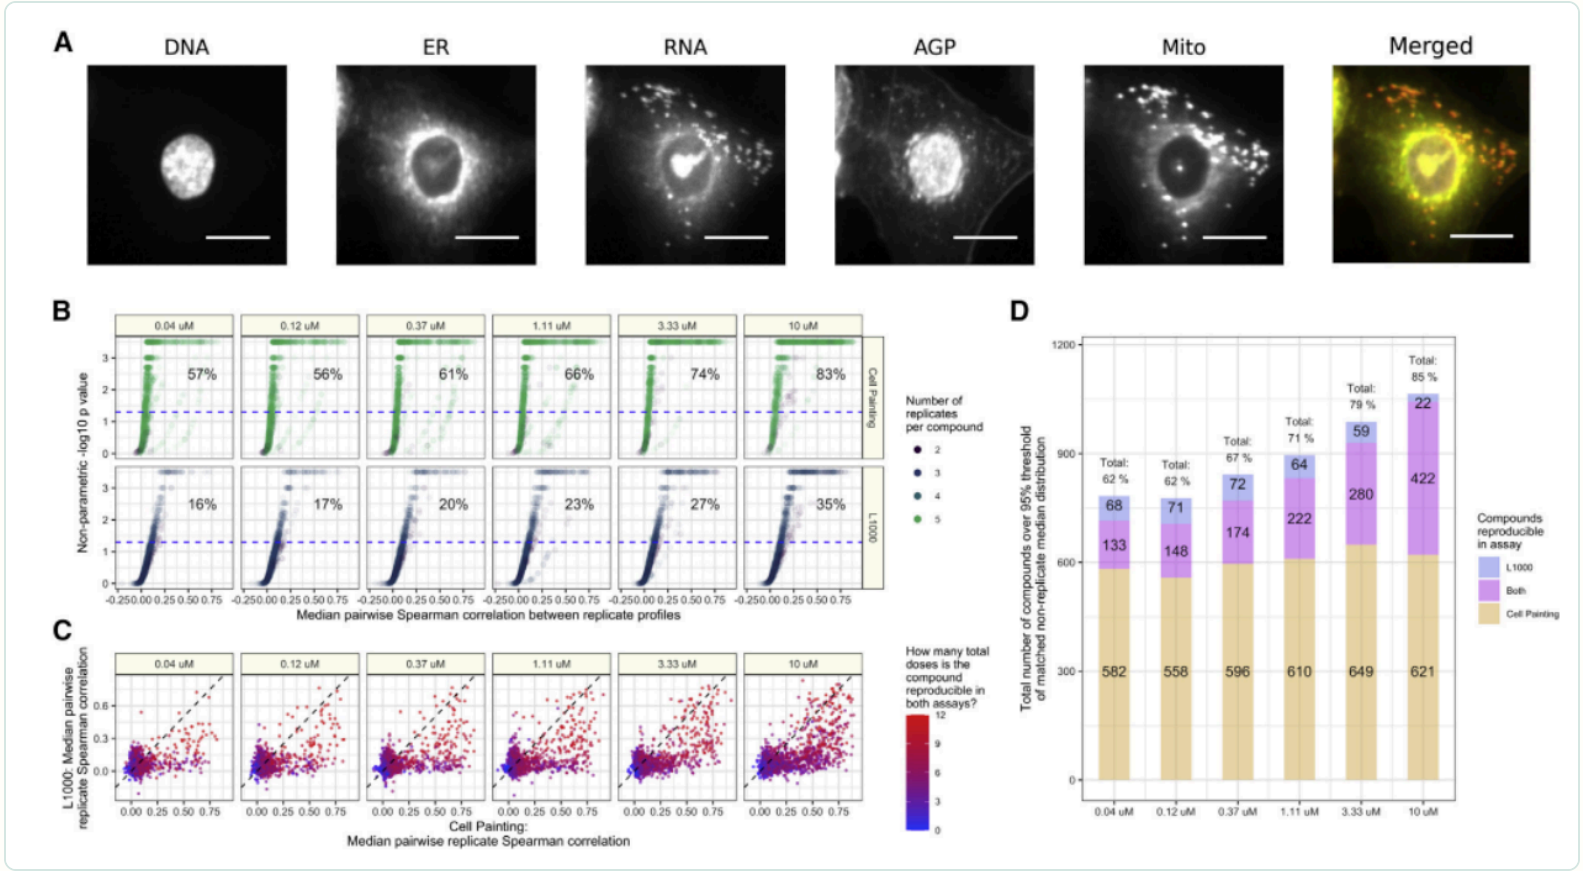
1. **PCA** trên đặc trưng giếng đối chứng âm (không nhất thiết cắt chiều).
2. **Chuẩn hóa từng trục** về trung bình 0, phương sai 1 trên đối chứng.
3. **Căn chỉnh tương quan theo lô** (CORAL / Sun et al.): whiten theo Σ đối chứng từng lô, recolor theo Σ toàn thí nghiệm.

$$z = \widehat{\mathrm{Cov}}_{\mathrm{ctrl}}^{-1/2}\left(x - \hat{\mu}_{\mathrm{ctrl}}\right) \quad \text{(whitening / sphering)}$$

Cov = ma trận hiệp phương sai (không phải ký hiệu tổng). TVN thêm PCA + CORAL theo lô (Ando) — xem Fig. 3 và MATH_NOTES §2.

BỔ SUNG NGỮ CẢNH · HÌNH TỪ PAPER

Cell Painting (nhuộm–ảnh) và L1000 bổ sung nhau trên thuốc (Way Fig. 1)



Nguồn: Way et al., Cell Systems 2022, Fig. 1 · DOI 10.1016/j.cels.2022.10.001 · ngữ cảnh hợp chất

THÍ NGHIỆM NHÓM

Giao hồ sơ giữa A → B → C

A xuất
CP_0 chưa chỉnh
CP_1 sphering/TVN
cùng ID nhiễu loạn

→

B chạy 2 lần
Lasso / MLP
L1000 giữ nguyên
% gen trên CP_0 và CP_1

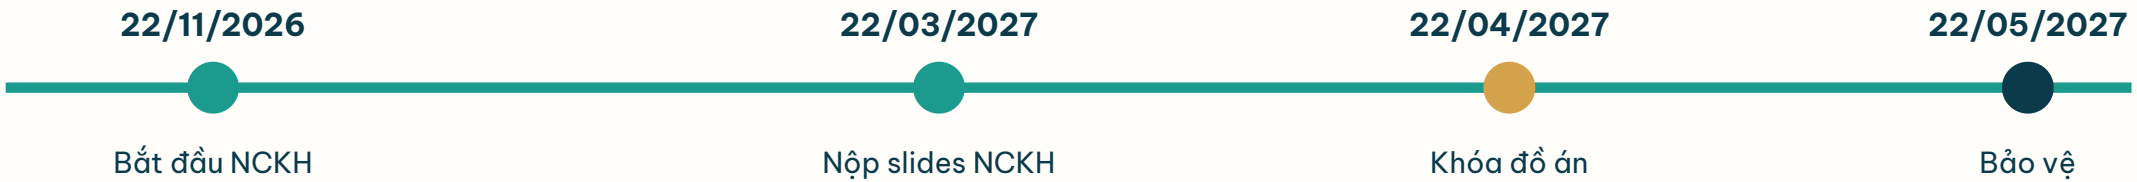
→

C ghi bảng Δ
Jaccard / F1
trước vs sau chỉnh nhiễu
cùng ID · CDRP-bio / LINCS

File giao	Nội dung	Ai đọc
`shared/cp_profiles_v0.parquet`	CP_0 + CP_1 + ID nhiễu loạn	B, C
`shared/percent_predictable.csv`	% gen · 4 tập · 2 phiên bản CP	C, slides
`shared/moa_scores.csv`	Jaccard / F1 · trước/sau	slides NCKH

SẢN PHẨM & LỊCH

Timeline 6 tháng

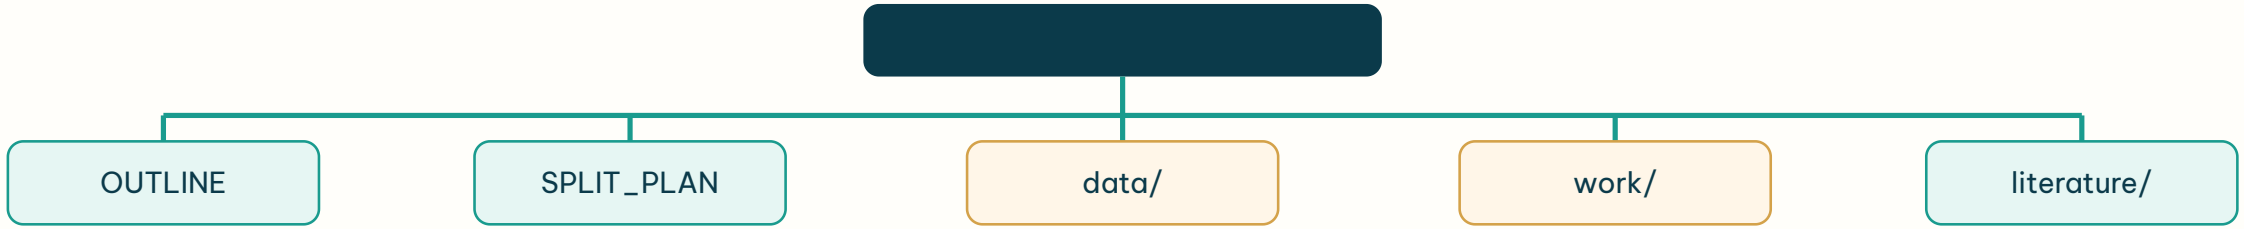


Giai đoạn	Thời gian	Sản phẩm
NCKH	4 tháng	data · quy trình · slides nhóm · 3 bảng số (A/B/C)
Khóa ĐA	1 tháng	đủ Phần 1–2–3 từng SV
Thủ tục	1 tháng	BV · clone sạch chạy lại

Họp 20:30 tối thứ Năm · Nộp NCKH: A benchmark · B % dự đoán · C ghép + Δ

BẢN ĐỒ FILE

Cây thư mục dự án



Nhu cầu	File
Bài toán & phạm vi	`OUTLINE.md`
Chi tiết từng SV / mục lục trang	`SPLIT_PLAN.md`
Link + lệnh data	`data/DATA.md`
Todos (PDF, Fig, công thức)	`work/role-a|b|c/TODOS.md`
PDF chụp + cite	`literature/papers/`
QC slides	`slides/nckh-briefing/QC_REPORT.md`

PHẠM VI DỰ ÁN

Khối việc trong 4 tháng

Định nghĩa

CP = nhuộm+ảnh→hồ sơ

L1000 ≈ 978 mRNA

Rosetta = neo 2 phép đo

LUAD·LINCS·CDRP·TA-ORF

Ba SV

A: chỉnh nhiễu CP

B: dự đoán chéo

C: fusion MoA

CDRP-bio / LINCS

Mở rộng

Way: hợp chất

JUMP / CPJUMP1

tầng ảnh

sau lõi Rosetta

Trọng tâm	Ngoài trọng tâm NCKH
thông tin chung / bổ sung · chỉnh nhiễu kỹ thuật	mô hình nhân quả Gene→RNA→kiểu hình làm trụ

THỨ TỰ ĐỌC PAPER

Chuỗi đọc: phép đo → hai hồ sơ → chỉnh nhiễu



#	Paper	Đọc để biết	Ai ưu tiên
1–2	Bray · Subramanian	phép đo CP / L1000	cả nhóm
3	Haghighi 2022	Rosetta · Fig. 2–4	cả nhóm
4	Rohban 2017	TA-ORF + CP	B
5–6	Way · Ando · Arevalo	bổ sung / TVN / batch	A, C
*	CPJUMP1	CRISPR/ORF tầng ảnh	mở rộng

20:30 tối thứ Năm

Việc cụ thể

1. Điền tên SV A/B/C vào `SPLIT_PLAN.md`; tạo repo `GITHUB.md`.
2. Sync Rosetta curated (slide data neo); ghi `data/inventory.md`.
3. Đọc Bray + Haghighi (định nghĩa hai phép đo + Hình 2–4).
4. Mỗi SV mở todo đầu trong `work/role-*/TODOS.md`.

Nhớ: L1000 = đo mRNA landmark · Cell Painting = nhuộm + ảnh → đặc trưng hình thái · họp 20:30 tối thứ Năm.

TÓM TẮT

Một trang nhớ lại

Bài toán

nhiễu loạn
→ CP + L1000
chung / bổ sung

Rosetta

Mục đích

% gen dự đoán
MoA fusion
chỉnh nhiễu

đo lại căn chỉnh

Dữ liệu

cpg0003
4 tập curated
+ JUMP / Way

hỗ trợ A

Ba ĐA

A: batch CP
B: Lasso/MLP
C: fusion MoA

SPLIT_PLAN D1–D3

Họp	Giao NCKH	Todos
20:30 tối thứ Năm	22/03/2027 · 3 bảng số	`work/role-a|b|c/TODOS.md`

Hết deck

Bắt đầu từ todos từng SV

`work/role-a|b|c/TODOS.md` · họp **20:30 tối thứ Năm**.